

TP Biais-variance – Partie 1 : fiche de synthèse

Pedro de Bem & Amanda Paula Fontenele – CentraleSupélec, Apprentissage automatique, 2026–2027

Sources utilisées

- HTF Hastie, Tibshirani, Friedman, *The Elements of Statistical Learning*, 2^e éd., Springer, 2009, chap. 7. *Manuel de référence*. Livre très cité, écrit par des statisticiens reconnus et relu par l'éditeur : on le considère comme fiable pour la partie « classique ».
- GBD Geman, Bienenstock, Doursat, « Neural Networks and the Bias/Variance Dilemma », *Neural Computation* 4(1), 1992. *Article de recherche* (revue à comité de lecture). Fiable et assez détaillé mathématiquement, mais ancien : ce qu'il dit sur les réseaux de neurones date d'avant le deep learning.
- BHMM Belkin, Hsu, Ma, Mandal, « Reconciling modern machine-learning practice and the classical bias–variance trade-off », *PNAS* 116(32), 2019. *Article de recherche* (revue à comité). Source récente et sérieuse, mais elle montre surtout des expériences (MNIST, etc.), pas une preuve que la double descente arrive toujours.
- SKL Documentation scikit-learn (v1.9), exemple « Underfitting vs. Overfitting », consultée le 4/10/2026. *Ressource pédagogique en ligne*. Officielle et reproductible (le code est fourni), mais pas relue par des pairs et sans aucune théorie.

1. Décomposition de l'erreur quadratique en un point x

Avec $y = f(x) + \varepsilon$, $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2$, et $\hat{f}_D$ le modèle appris sur le jeu D :

$$\mathbb{E}_{D,\varepsilon}[(y - \hat{f}_D(x))^2] = \underbrace{(f(x) - \mathbb{E}_D[\hat{f}_D(x)])^2}_{\text{biais}^2} + \underbrace{\text{Var}_D(\hat{f}_D(x))}_{\text{variance}} + \underbrace{\sigma^2}_{\text{bruit}} \quad ([\text{HTF}] \text{ éq. 7.9, } [\text{GBD}] \text{ §3.1})$$

On l'obtient en écrivant $y - \hat{f}_D = (f - \mathbb{E}_D \hat{f}_D) + (\mathbb{E}_D \hat{f}_D - \hat{f}_D) + \varepsilon$ et en développant le carré : les doubles produits sont nuls en moyenne car $\mathbb{E}_D[\hat{f}_D - \mathbb{E}_D \hat{f}_D] = 0$ et le bruit de test est indépendant de D . Le biais² mesure l'erreur systématique (la prédiction moyenne est loin de f , le modèle est trop simple). La variance mesure à quel point le modèle change quand on change de jeu d'entraînement. Le bruit σ^2 est irréductible : même en connaissant f exactement, on ferait encore cette erreur en moyenne.

2. Sur quoi porte l'espérance ?

Dans le biais et la variance, x est fixé et c'est le jeu d'entraînement D qui est aléatoire (on imagine tirer plein de jeux de même taille n et réentraîner le même modèle à chaque fois). [GBD] le dit clairement : $\mathbb{E}_D$ est la moyenne « sur l'ensemble des D possibles, à N fixé ». Dans l'erreur totale, on ajoute en plus le bruit ε du nouveau point de test. C'est pour ça que le TP tire $M = 200$ jeux : en vrai on n'en a qu'un, donc biais et variance ne sont pas observables directement.

3. Et pour la perte 0-1 en classification ?

Non, pas sous la forme « bruit + biais² + variance ». [HTF] (§7.3.1 et fig. 7.3) montre que l'erreur de classification n'est plus la somme des deux : biais et variance « interagissent ». Exemple du livre : si $P(Y = 1 | x) = 0,9$ et que l'estimation moyenne vaut 0,6, le biais² est grand mais on prédit quand même la bonne classe, donc l'erreur ne bouge pas. Ce qui compte, c'est de passer ou non du mauvais côté du seuil 1/2. Dans l'exercice 7.2 (d'après Friedman 1997), biais et variance se combinent de façon multiplicative : si la prédiction moyenne est du mauvais côté du seuil, augmenter la variance peut même réduire l'erreur ! Il existe d'autres décompositions pour la perte 0-1, mais avec des définitions de biais et de variance différentes.

4. La « double descente »

D'après [BHMM], quand on augmente la capacité du modèle (nombre de paramètres N), l'erreur de test suit d'abord la courbe en U classique, puis a un pic au seuil d'interpolation (le modèle a juste assez de paramètres pour passer par tous les points, erreur d'entraînement nulle, ex. $N \approx n$), et ensuite redescend quand on continue à ajouter des paramètres. Cette seconde descente apparaît dans le régime sur-paramétré (à droite du seuil), observé pour des random features, des réseaux de neurones et des forêts aléatoires. L'explication proposée : parmi toutes les solutions qui interpolent, l'algorithme choisit celle de plus petite norme, qui est plus « lisse ». Le nombre de paramètres mesure donc mal la complexité réelle.

5. Leviers pratiques

Réduire la variance : (i) avoir plus de données d'entraînement ; (ii) régulariser (Ridge, augmenter α) ou simplifier le modèle (degré plus bas, k plus grand en k -NN). Réduire le biais : (i) prendre un modèle plus flexible (degré plus élevé, k plus petit, plus de neurones) ; (ii) diminuer une régularisation trop forte ou ajouter de meilleures variables (features). Chaque levier peut augmenter l'autre terme, d'où l'intérêt de la validation croisée ([SKL]).

Points où les sources divergent

- Notations. [HTF] écrit $\sigma_\varepsilon^2 + \text{Bias}^2 + \text{Var}$ avec un $\mathbb{E}$ sans indice, alors que [GBD] écrit $f(x; D)$ et $\mathbb{E}_D$. Surtout, [GBD] décompose l'erreur par rapport à $\mathbb{E}[y | x]$, donc sans le terme de bruit, et appelle « bias » directement le terme au carré. Le sujet du TP, lui, utilise $\hat{f}_D$ et $\mathbb{E}_{D,\varepsilon}$.
- Fond. [BHMM] cite [HTF] p. 221 (« un modèle à erreur d'entraînement nulle est sur-ajusté et généralise mal ») pour le contredire avec la double descente. La décomposition reste vraie, c'est l'idée « plus de paramètres = plus de variance » qui ne l'est plus toujours. [SKL], de son côté, ne parle pas du tout de biais et de variance : il présente seulement sous-/sur-apprentissage (degrés 1, 4, 15) et l'erreur en validation croisée.